UNIVERSIDAD NACIONAL DEL SANTA

Facultad de Ingeniería

Escuela Profesional de Ingeniería de Sistemas e Informática

Curso: Ingeniería de Software II

Producto de la Unidad I

NewBit

Sistema web con visión artificial para la detección de actos inseguros en áreas operativas de manufactura metalmecánica

Código del proyecto: PY-NB-001

Integrantes (Grupo D3)

Chumacero Chávarry, Albert Sebastian	*Product Owner*
Lopez Yrribarren, Anthony Gabriel	*Scrum Master* y *Developer*
Salazar Diaz, Luis Fernando	*Developer*

Docente

Dr. Ing. Alfredo Daza Vergaray

Nuevo Chimbote, Perú

Octubre de 2026

Índice

1 Introducción **4**

2 Antecedentes **5**
2.1 Antecedentes internacionales 5
2.2 Antecedentes nacionales 5
2.3 Síntesis de los antecedentes 6

3 Marco teórico **7**
3.1 Seguridad y salud en el trabajo: actos inseguros 7
3.2 Scrum y la Guía SBOK 7
3.3 Ingeniería de requisitos ágil 8
3.4 Priorización y estimación 8
3.5 Visión artificial y aprendizaje profundo 8
3.6 Modelado temporal: LSTM y ConvLSTM 9
3.7 Métricas de evaluación 9

4 Desarrollo **9**
4.1 Evolución de la propuesta 10
4.2 FGAP010: Acta de constitución del proyecto 12
4.3 FGAP020: Registro de interesados 15
4.4 FGAP030: Roles y prototipos 16
4.5 EGAP015: Justificación del proyecto 17
4.6 FGAP040: Épicas e historias de usuario 18
4.7 FGAP060: Backlog priorizado del producto 20
4.8 FGAP070: Criterios de terminado 21
4.9 Arquitectura propuesta y plan de sprints 22

Referencias **24**

Índice de tablas

Tabla 1 Síntesis de los antecedentes revisados . . . 7
Tabla 2 Formatos del proyecto y su estado al 19 de octubre de 2026 . . . 10
Tabla 3 Evolución de la propuesta, de VIGIA Industrial a NewBit . . . 11
Tabla 4 Síntesis del acta de constitución (FGAP010) . . . 12
Tabla 5 Requisitos del proyecto . . . 13
Tabla 6 Riesgos generales y respuesta prevista . . . 14
Tabla 7 Cronograma de hitos . . . 14
Tabla 8 Presupuesto estimado del proyecto . . . 15
Tabla 9 Registro de interesados (FGAP020) . . . 16
Tabla 10 Roles de usuario de NewBit (FGAP030) . . . 17
Tabla 11 Síntesis de la justificación del proyecto (EGAP015) . . . 18
Tabla 13 Historias de usuario y criterios de aceptación . . . 18
Tabla 12 Épicas del proyecto (FGAP040) . . . 20
Tabla 14 Backlog priorizado del producto (FGAP060) . . . 21
Tabla 15 Criterios de terminado del incremento (FGAP070) . . . 22

Índice de figuras

Figura 1 Secuencia de formatos del proyecto y avance al cierre de la Unidad I . . . 10
Figura 2 Matriz de poder e interés de los interesados . . . 15
Figura 3 Arquitectura propuesta del pipeline de NewBit . . . 23
Figura 4 Plan de sprints de NewBit, octubre a diciembre de 2026 . . . 23

1. Introducción

En las plantas de manufactura metalmecánica conviven máquinas herramienta, tableros eléctricos, pasillos peatonales y equipos de transporte interno. En ese entorno, una parte importante de los accidentes no se origina en una falla del equipo, sino en una conducta de la persona: cruzar fuera de la vía peatonal señalizada o dejar abierto un tablero de control después de intervenirlo. La teoría clásica de prevención distingue entre *actos inseguros* y *condiciones inseguras* y ubica a los primeros como causa frecuente de accidentes (Heinrich, 1931). En el Perú, la Ley N.º 29783 exige al empleador un enfoque preventivo de la seguridad y salud en el trabajo (SST) (Congreso de la República del Perú, 2011).

La supervisión de estas conductas, sin embargo, sigue siendo intermitente: el inspector de SST recorre la planta por turnos y las cámaras de videovigilancia graban horas de video que casi nadie revisa. El resultado es que el acto inseguro se detecta tarde o no se detecta. La visión artificial ofrece una alternativa: analizar el video ya grabado para identificar automáticamente las secuencias en las que ocurre una conducta de riesgo y presentar la evidencia a la persona responsable.

NewBit (PY-NB-001) es el proyecto del Grupo D3 que aborda ese problema. Se trata de un sistema web que recibe videos industriales por lotes, detecta a los operarios con un modelo de detección de objetos (YOLOv8), descarta los fotogramas sin actividad, agrupa los restantes en secuencias y las clasifica con una red convolucional recurrente (ConvLSTM) como conductas seguras o inseguras. Su base científica es Unsafe-Net, la arquitectura de dos etapas propuesta por Önal y Dandıl (2025), y su fuente de datos es el conjunto público que esos autores publicaron con licencia CC BY 4.0 (Önal y Dandıl, 2024a). El proyecto se gestiona con Scrum, siguiendo la *Guía de los fundamentos de Scrum* (SCRUMstudy, 2022), en cuatro sprints de dos semanas.

La propuesta no nació en su forma actual. Comenzó como una plataforma para verificar el uso de casco y chaleco con cámaras en vivo y, tras dos iteraciones, se convirtió en un sistema que reconoce conductas a partir de video grabado. Ese recorrido, y las razones de cada cambio, forman parte de este documento.

Este documento es el producto de la Unidad I del curso. Su **objetivo general** es presentar de manera integrada la fase de inicio y planificación de NewBit, desde la definición del proyecto hasta el backlog priorizado y los criterios de terminado. Sus objetivos específicos son:

a) Revisar los antecedentes nacionales e internacionales que sustentan el uso de visión artificial para la seguridad laboral.

b) Exponer el marco teórico de Scrum, de la ingeniería de requisitos ágil y de los modelos de visión artificial que emplea el proyecto.

c) Describir cómo evolucionó la propuesta y qué motivó cada cambio.

d) Desarrollar, en el orden de la secuencia de avances del curso, los formatos FGAP010, FGAP020, FGAP030, EGAP015, FGAP040, FGAP060 y FGAP070 aplicados a NewBit,

junto con la arquitectura propuesta y el plan de sprints.

El documento se organiza en cuatro partes. La sección 2 revisa los antecedentes; la sección 3, el marco teórico; la sección 4 desarrolla los formatos de gestión y el estado del proyecto, y al final se listan las referencias en formato APA.

2. Antecedentes

2.1. Antecedentes internacionales

Önal y Dandıl (2021) aplicaron YOLOv4 para detectar elementos de seguridad y equipos de protección personal en entornos de trabajo. Reportaron un mAP de 91.18 %, una precisión de 0.89, una sensibilidad (*recall*) de 0.91 y un F1 de 0.90. Su aporte para este proyecto es mostrar el punto de partida de la línea de investigación: la detección espacial, cuadro por cuadro, de objetos asociados a la seguridad. Un único fotograma, sin embargo, no basta para describir una acción, y esa fue la limitación que la línea abordó después.

Esa limitación motivó Unsafe-Net (Önal y Dandıl, 2025), un sistema de dos etapas para detectar en tiempo real conductas inseguras en una fábrica. En la primera etapa, YOLOv4 identifica los fotogramas relevantes y reduce cada clip; en la segunda, una red ConvLSTM clasifica la secuencia reducida. Los autores trabajaron con 39 días de video, aproximadamente 4 000 horas, grabado con dos cámaras IP en una planta metalmecánica y de plásticos de Eskişehir (Turquía). El detector alcanzó un mAP de 95.66 % con un umbral de IoU de 0.5. La clasificación temporal obtuvo una exactitud promedio por clase de 85.78 % sin reducción de fotogramas y de 95.81 % con el pipeline completo, y el tiempo medio de reconocimiento sobre el clip ya reducido fue de 0.14 s. Los autores aclaran que este último valor no es la latencia total: en un ejemplo que incluye la reducción con YOLO estiman cerca de 1.34 s. También reportan un piloto en planta con validación de un experto en SST.

El conjunto de datos de ese estudio se documenta en Önal y Dandıl (2024b) y se publica en Mendeley Data (Önal y Dandıl, 2024a). Contiene 691 clips (566 de entrenamiento y 125 de prueba) a 1920×1080 píxeles y 24 cuadros por segundo, distribuidos en ocho clases: cuatro conductas inseguras (tránsito fuera de la vía peatonal, intervención no autorizada, tapa de panel abierta y sobrecarga con montacargas) y sus cuatro contrapartes seguras. Su aporte es doble: permite reproducir el problema con datos reales y ofrece una división oficial de entrenamiento y prueba que NewBit respeta sin modificar.

2.2. Antecedentes nacionales

Gutiérrez Torres (2022), en la Pontificia Universidad Católica del Perú, evaluó si el aprendizaje profundo puede reconocer equipos de seguridad en obras de construcción para alertar a los supervisores sobre su uso inadecuado. Construyó un conjunto de imágenes con variaciones de postura, iluminación, oclusión y aglomeración, y comparó VGG-16, ResNet-18

e Inception-V3; el mejor prototipo, con Inception-V3, alcanzó una exactitud de 84 %. Su aporte es metodológico: muestra la importancia de un conjunto de datos variado y de comparar arquitecturas antes de elegir una.

Machaca Arcana (2019), en la Universidad Nacional de San Agustín de Arequipa, desarrolló un sistema para reconocer eventos anómalos en videos de cámaras de vigilancia sin intervención humana. Empleó redes convolucionales para detectar personas, analizar acciones y seguir sus patrones de movimiento, y revisó detectores como YOLO, R-CNN y SSD. Es el antecedente nacional más cercano al enfoque de NewBit, porque trabaja con video y con acciones, no con imágenes aisladas.

Paucara Guadalupe y Rodríguez Enciso (2024), en la Universidad César Vallejo, propusieron un sistema inteligente basado en aprendizaje profundo para detectar el uso correcto del casco como equipo de protección personal. Con un diseño experimental de preprueba y posprueba, concluyeron que el sistema identifica el casco con mayor exactitud que los métodos convencionales de supervisión. Su aporte es mostrar cómo evaluar el efecto de un sistema de visión en la tarea del supervisor y no solo la métrica del modelo.

León León y León Montero (2024), de la Universidad Privada del Norte, desarrollaron un algoritmo de visión artificial con YOLOv8, Python y OpenCV para verificar en tiempo real el uso correcto de mascarilla y gorro. Entrenaron con más de 1 500 imágenes etiquetadas y reportaron una tasa de validación de 96.57 %. Su aporte es confirmar la viabilidad de YOLOv8, la misma familia de modelos que usa NewBit, con herramientas abiertas y en un contexto peruano.

2.3. Síntesis de los antecedentes

La Tabla 1 resume los trabajos revisados. Los estudios nacionales se concentran en detectar objetos, sobre todo equipos de protección, en imágenes. Unsafe-Net, en cambio, reconoce conductas a lo largo del tiempo. NewBit se ubica en ese segundo grupo: no pregunta si el operario lleva casco, sino qué hace durante una secuencia, y lo hace en un contexto de manufactura metalmecánica con un pipeline que separa la etapa espacial de la temporal.

Tabla 1
Síntesis de los antecedentes revisados

Autor (año)	Ámbito	Técnica principal	Unidad	Resultado reportado
Önal y Dandıl (2021)	Turquía	YOLOv4, detección de EPP	Imagen	mAP 91.18 %
Önal y Dandıl (2025)	Turquía	YOLOv4 + ConvLSTM, conductas inseguras	Video	Exactitud por clase 95.81 %
Önal y Dandıl (2024b)	Turquía	Conjunto de datos de conductas seguras e inseguras	Video	691 clips, 8 clases
Gutiérrez Torres (2022)	Perú	VGG-16, ResNet-18, Inception-V3	Imagen	Exactitud 84 %
Machaca Arcana (2019)	Perú	Redes convolucionales, eventos anómalos	Video	No se consigna cifra en el resumen
Paucara Guadalupe y Rodríguez Enciso (2024)	Perú	Aprendizaje profundo, detección de casco	Imagen	Mejora frente al método convencional
León León y León Montero (2024)	Perú	YOLOv8, mascarilla y gorro	Imagen	Validación 96.57 %

Nota. EPP = equipo de protección personal. Las cifras son las que reporta cada autor en su propio conjunto de datos y no son comparables entre sí.

3. Marco teórico

3.1. Seguridad y salud en el trabajo: actos inseguros

Un *acto inseguro* es una acción u omisión de la persona que la expone a ella o a otros a un riesgo, como transitar fuera de la vía peatonal o dejar abierto un tablero eléctrico. Se diferencia de la *condición insegura*, que es un estado peligroso del entorno, como un piso resbaladizo o una guarda faltante. Heinrich (1931) formuló esta distinción y sostuvo que la mayor parte de los accidentes se explica por actos inseguros, de modo que la prevención debe actuar sobre la conducta. En el Perú, la Ley N.º 29783 establece el principio de prevención y obliga al empleador a garantizar condiciones que protejan la vida y la salud de los trabajadores (Congreso de la República del Perú, 2011). NewBit se plantea como una herramienta de apoyo a ese deber: no reemplaza al supervisor ni certifica el cumplimiento de la norma, sino que le entrega evidencia oportuna.

3.2. Scrum y la Guía SBOK

Scrum es un marco de trabajo ágil para desarrollar productos complejos de forma iterativa e incremental (Schwaber y Sutherland, 2020). La Guía SBOK organiza Scrum en principios, aspectos y procesos (SCRUMstudy, 2022). Sus seis principios son el control del proceso empí-

rico (transparencia, inspección y adaptación), la autoorganización, la colaboración, la priorización basada en el valor, el *time-boxing* y el desarrollo iterativo.

Los roles centrales son tres. El *Product Owner* maximiza el valor del producto, gestiona el backlog y acepta o rechaza los entregables. El *Scrum Master* facilita el proceso y elimina impedimentos. El *Equipo Scrum* construye el incremento. El trabajo avanza en *sprints* de duración fija, de una a cuatro semanas, con eventos acotados en el tiempo: planificación del sprint, reunión diaria de 15 minutos, revisión y retrospectiva (SCRUMstudy, 2022). Antes de los sprints, la fase de inicio produce la visión, el acta del proyecto, la identificación de los interesados, las épicas y el backlog priorizado.

3.3. Ingeniería de requisitos ágil

En Scrum, los requisitos se expresan como *historias de usuario*: descripciones breves de una funcionalidad desde el punto de vista de quien la necesita, con la forma «Como [rol], quiero [funcionalidad], para [beneficio]» (Cohn, 2004; Menzinsky et al., 2018). Las *épicas* agrupan historias relacionadas que todavía son demasiado grandes para un sprint. Cada historia lleva *criterios de aceptación*, que son condiciones específicas y verificables que el Product Owner usa para aceptarla. Por encima de ellos, los *criterios de terminado* (*Definition of Done*) son comunes a todas las historias y fijan el nivel mínimo de calidad del incremento, como pruebas, revisión de pares y documentación (SCRUMstudy, 2022).

3.4. Priorización y estimación

La técnica **MoSCoW** clasifica los requisitos en cuatro grupos: los que el producto debe tener (*Must have*), debería tener (*Should have*), podría tener (*Could have*) y no tendrá en esta versión (*Won't have*) (Clegg y Barker, 1994). El **método de los 100 puntos** reparte 100 puntos por integrante entre las historias, lo que convierte la importancia relativa en un número que se puede sumar (SCRUMstudy, 2022). Para estimar, el **puño de cinco** (*Fist of Five*) pide que cada integrante muestre a la vez de uno a cinco dedos; si hay diferencias grandes, quienes votaron en los extremos explican sus razones y se vuelve a votar (SCRUMstudy, 2022). El resultado se expresa en *puntos de historia*, una medida relativa del esfuerzo.

3.5. Visión artificial y aprendizaje profundo

El aprendizaje profundo emplea redes neuronales con muchas capas que aprenden representaciones de los datos directamente a partir de ejemplos (LeCun et al., 2015). Para imágenes, las redes neuronales convolucionales (CNN) aplican filtros que detectan bordes, texturas y formas cada vez más complejas.

La *detección de objetos* localiza y clasifica objetos en una imagen mediante cajas delimitadoras. La familia YOLO (*You Only Look Once*) resuelve la detección como un único problema de regresión sobre la imagen completa, lo que la hace rápida y adecuada para video (Redmon

et al., 2016). YOLOv4 incorporó mejoras de entrenamiento y arquitectura para equilibrar velocidad y precisión (Bochkovskiy et al., 2020), y es la versión que usó Unsafe-Net. YOLOv8, de Ultralytics, es una implementación más reciente y de código abierto, con modelos preentrenados de varios tamaños; NewBit usa su variante más liviana, YOLOv8n (Jocher et al., 2023).

3.6. Modelado temporal: LSTM y ConvLSTM

Una conducta no se reconoce en un solo fotograma, sino en la evolución de varios. Las redes LSTM (*Long Short-Term Memory*) son redes recurrentes con compuertas que deciden qué información conservar u olvidar, lo que les permite aprender dependencias de largo plazo en secuencias (Hochreiter y Schmidhuber, 1997). La ConvLSTM sustituye las multiplicaciones matriciales internas de la LSTM por convoluciones, de modo que conserva la estructura espacial de cada fotograma mientras modela su evolución en el tiempo (Shi et al., 2015). Esa propiedad la hace adecuada para clasificar clips de video, como en Unsafe-Net.

3.7. Métricas de evaluación

Para la detección se usa la intersección sobre la unión (IoU), que mide el solapamiento entre la caja predicha B_p y la real B_r, y la precisión media (mAP) a un umbral de IoU dado:

$$\text{IoU} = \frac{|B_p \cap B_r|}{|B_p \cup B_r|} \tag{1}$$

Para la clasificación de conductas, con VP, FP y FN como verdaderos positivos, falsos positivos y falsos negativos:

$$\text{Precisión} = \frac{VP}{VP + FP}, \qquad \text{Sensibilidad} = \frac{VP}{VP + FN} \tag{2}$$

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} \tag{3}$$

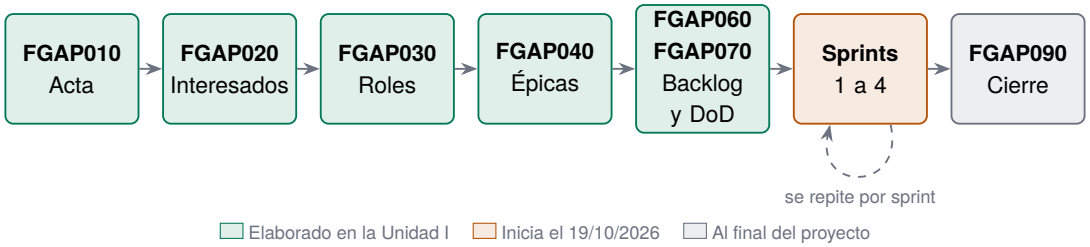
La exactitud puede agregarse de dos formas: *micro*, sobre el total de clips, o *macro*, como promedio de la exactitud de cada clase. Unsafe-Net reporta el promedio por clase; por eso NewBit reportará ambas, además de la matriz de confusión.

4. Desarrollo

Esta sección comienza por la evolución de la propuesta y luego desarrolla los formatos del proyecto en el orden que fija la secuencia de avances del curso (Daza Vergaray, 2026b), representada en la Figura 1. La Tabla 2 indica el estado de cada formato al cierre de la Unidad I.

Figura 1

Secuencia de formatos del proyecto y avance al cierre de la Unidad I



Nota. Elaboración propia a partir de la secuencia de trabajo del proyecto entregada por el docente (Daza Vergaray, 2026b). La Justificación (EGAP015) acompaña a la secuencia como documento de apoyo.

Tabla 2

Formatos del proyecto y su estado al 19 de octubre de 2026

Formato	Documento	Semana	Estado
FGAP010	Acta de constitución del proyecto	2	Versión 2.0 aprobada
FGAP020	Registro de interesados	6	Versión 1.0, elaborada en este producto
FGAP030	Roles y prototipos	3	Versión 2.0 aprobada
EGAP015	Justificación del proyecto	4	Versión 2.0 aprobada
FGAP040	Épicas e historias de usuario	4	Versión 2.0: 6 épicas y 12 historias
FGAP060	Backlog priorizado del producto	5	Versión 2.0: MoSCoW, 100 puntos y estimación
FGAP070	Criterios de terminado	5	Versión 1.0 aprobada
FGAP090	Cierre del proyecto	—	Previsto para diciembre de 2026

Nota. La columna Semana indica la semana del curso en que se elaboró el formato.

4.1. Evolución de la propuesta

Scrum asume que el producto se descubre inspeccionando y adaptando (SCRUMstudy, 2022). La propuesta de NewBit siguió ese principio desde antes del primer sprint: pasó por tres versiones, y cada cambio respondió a un problema concreto detectado en la anterior.

Primera versión: VIGIA Industrial (semanas 2 y 3). El equipo, entonces de dos integrantes, propuso una plataforma que convirtiera las cámaras existentes de una planta siderúrgica en sensores configurables. El primer caso de uso era verificar el uso de casco y chaleco y el ingreso a zonas restringidas en cuatro cámaras en vivo, con un detector YOLO, seguimiento de personas y reglas por zona. Al revisarla se identificaron dos problemas. El primero, que detectaba *objetos* (si hay o no casco) y no *conductas*. El segundo, que dependía de un piloto en planta

y de video local que el equipo no tenía garantizados.

Segunda versión: elección de Unsafe-Net (semana 4). El equipo comparó tres investigaciones de visión artificial aplicada a la seguridad industrial y eligió Unsafe-Net (Önal y Dandıl, 2025) el 5 de octubre de 2026. La razón fue doble: reconoce conductas a lo largo del tiempo, no objetos aislados, y su conjunto de datos es público (Önal y Dandıl, 2024a), lo que eliminaba el mayor riesgo de la versión anterior. El equipo quedó conformado por tres integrantes, y el rol de Product Owner, antes asignado a una persona externa ficticia, pasó a uno de ellos.

Tercera versión: NewBit normalizado (semana 5). Una revisión cruzada de todos los formatos encontró inconsistencias que se corrigieron en cascada. El entorno siderúrgico no correspondía al video del conjunto de datos, grabado en un taller metalmecánico, y se cambió. Las cámaras en vivo no eran demostrables y se reemplazaron por procesamiento de video por lotes. Las 26 historias preliminares, sin criterios ni prioridad, se consolidaron en 12 historias con criterios de aceptación. Los roles de laboratorio («investigador», «evaluador») se sustituyeron por usuarios de planta. La Tabla 3 resume el cambio.

Tabla 3
Evolución de la propuesta, de VIGIA Industrial a NewBit

Aspecto	VIGIA Industrial (semanas 2–3)	NewBit (versión actual)	Motivo del cambio
Qué detecta	Objetos: casco, chaleco, ingreso a zona	Conductas: tránsito fuera de la vía peatonal y tablero abierto	Un acto inseguro se reconoce en una secuencia, no en un fotograma
Entrada	Cuatro cámaras en vivo (RTSP)	Video grabado, procesado por lotes	Alcance demostrable sin acceso a planta
Datos	Video local por conseguir	Conjunto público con licencia CC BY 4.0	Elimina el mayor riesgo del proyecto
Modelo	YOLO con seguimiento y reglas por zona	YOLOv8 + ConvLSTM, en dos etapas	Separar lo espacial de lo temporal
Entorno	Planta siderúrgica	Taller de manufactura metalmecánica	Coherencia con el video del conjunto de datos
Backlog	26 historias sin criterios	12 historias con criterios, prioridad y estimación	Historias verificables y planificables
Equipo	Dos integrantes; PO externo	Tres integrantes; PO del equipo	Ajuste a los roles de Scrum
Presupuesto	S/ 30 820	S/ 20 768	Menor alcance y sin hardware nuevo

Nota. Elaboración propia a partir de las versiones del acta y de la bitácora de decisiones del equipo.

Lo que se conservó entre versiones también es significativo: el análisis de video sin

reconocimiento facial, la decisión final en manos de una persona y la evaluación del evento completo antes que del fotograma aislado.

4.2. FGAP010: Acta de constitución del proyecto

El acta define el proyecto y autoriza su inicio. Su visión es transformar el registro pasivo de las cámaras de una planta de manufactura metalmecánica en un sistema que detecte y registre actos inseguros a partir de video grabado, con alertas oportunas para el área de SST y sin reconocimiento facial. La organización es un caso académico propuesto, equivalente al entorno del conjunto de datos; los nombres de sus representantes son ficticios. La Tabla 4 resume sus campos.

Tabla 4
Síntesis del acta de constitución (FGAP010)

Campo	Contenido
Código y nombre	PY-NB-001: Sistema web con visión artificial para la detección de actos inseguros en áreas operativas de manufactura metalmecánica (nombre comercial: NewBit)
Alcance	Dos conductas de la primera versión: tránsito fuera de la vía peatonal y tablero eléctrico abierto, con sus casos seguros de contraste. Datos: conjunto de Önal y Dandıl (2024a), con su división oficial. Evaluación: clasificación temporal directa frente al pipeline completo YOLOv8 + ConvLSTM.
Fuera del alcance	Instalación en planta, cámaras en vivo (RTSP), alertas físicas en la máquina, reconocimiento facial e identificación de trabajadores, y certificación oficial de SST.
Entregables clave	Formatos de gestión, frames anotados y modelo YOLOv8, modelo ConvLSTM evaluado, plataforma web con registro y alerta, e informe técnico.
Criterios de aprobación	Pipeline completo en funcionamiento; etapas espacial y temporal evaluables por separado; reducción de fotogramas demostrada con datos; métricas por clase y tiempos; resultados reproducibles.
Product Owner	Albert Sebastian Chumacero Chávarry, que reporta al sponsor.
Sponsor	Ricardo Salcedo Paredes, gerente general de la empresa del caso.

Los requisitos se dividen en funcionales y no funcionales (Tabla 5). Los no funcionales responden a la naturaleza experimental del proyecto: un resultado de visión artificial solo es defendible si se puede reproducir y si el conjunto de prueba no se toca.

La Tabla 6 recoge los riesgos y su respuesta. El de mayor impacto es técnico: el ajuste del modelo temporal. El último es organizativo: el equipo tiene tres integrantes y el Scrum Master también desarrolla.

Los riesgos se revisan en cada reunión diaria y en cada retrospectiva. Si uno se materia-

Tabla 5
Requisitos del proyecto

Código	Requisito
Funcionales	
RF-01	Cargar clips de video industrial.
RF-02	Detectar personas y objetos de interés fotograma a fotograma con YOLOv8.
RF-03	Conservar solo los fotogramas relevantes según una regla explícita y configurable.
RF-04	Agrupar los fotogramas conservados en secuencias.
RF-05	Clasificar cada secuencia con ConvLSTM como conducta segura o insegura.
RF-06	Registrar por clip el archivo, la clase, la confianza, el tiempo de proceso y los fotogramas originales y conservados.
RF-07	Mostrar una alerta visual y sonora ante una conducta insegura.
No funcionales	
RNF-01	Reproducibilidad: configuración versionada, semillas fijas y puntos de control del modelo.
RNF-02	Separación estricta entre entrenamiento y prueba con la división oficial del conjunto de datos.
RNF-03	Métricas por clase y registro de tiempos de procesamiento.
RNF-04	Uso del conjunto de datos con atribución, según la licencia CC BY 4.0.
RNF-05	Privacidad por diseño: sin reconocimiento facial ni identificación de personas.

Nota. Los códigos RNF se asignan en este documento para referenciar los requisitos no funcionales del acta.

liza, el acta prevé un cierre con alcance reducido: entregar una sola conducta con su evaluación documentada, en lugar de dos.

El cronograma (Tabla 7) abarca once semanas calendario, del 5 de octubre al 18 de diciembre de 2026. Las dos primeras semanas corresponden a la fase de inicio, en la que se elaboraron los formatos de este documento; le siguen cuatro sprints de dos semanas, separados por un fin de semana que sirve de margen para la revisión y la retrospectiva, y una semana final de entrega y cierre.

El presupuesto (Tabla 8) asciende a S/ 20 768. El 90 % corresponde a la dedicación valorizada de los tres integrantes, calculada con tarifas referenciales por hora. El gasto en efectivo previsto es pequeño, S/ 280, porque el conjunto de datos y el software son abiertos y el equipo usa sus propias computadoras. La contingencia del 10 % sirve de margen ante imprevistos, como necesitar más horas de GPU durante el entrenamiento del Sprint 3.

Tabla 6
Riesgos generales y respuesta prevista

Riesgo	Respuesta
Ajuste del modelo temporal (longitud de secuencia, capas, hiperparámetros)	Experimentación controlada y registro de cada configuración.
Implementación propia del pipeline completo	Bibliotecas abiertas y probadas; revisión de código entre pares.
GPU y tiempo de entrenamiento limitados	Priorizar las dos conductas; usar Colab o GPU local con una bolsa de cómputo en la nube.
Etiquetado de fotogramas más lento de lo previsto	Muestreo representativo y priorización de las clases elegidas.
Espacio en disco (30 a 50 GB entre videos, fotogramas y modelos)	Almacenamiento externo o en la nube.
Cambio de entorno: una planta y dos cámaras	La adaptación a otras plantas se planifica como evolución del producto.
Equipo de tres integrantes; el Scrum Master también es Developer	*Time-boxing* estricto y revisión de pares entre los dos Developers.

Tabla 7
Cronograma de hitos

Hito y resultado verificable	Inicio	Fin
Inicio del proyecto: acta y formatos de gestión iniciales	05/10/2026	16/10/2026
Sprint 1: datos, conductas de la primera versión, entorno de trabajo, ingesta y detección	19/10/2026	30/10/2026
Sprint 2: reducción de fotogramas, segmentación de clips y configuración de umbrales	02/11/2026	13/11/2026
Sprint 3: modelo ConvLSTM, pipeline completo y evaluación comparativa	16/11/2026	27/11/2026
Sprint 4: interfaz, registro, alerta, pruebas integradas e informe técnico	30/11/2026	11/12/2026
Entrega, revisión final y cierre	14/12/2026	18/12/2026

Nota. Los objetivos de cada sprint se expresan según el backlog priorizado (Tabla 14), que es posterior al acta y prevalece sobre ella.

Tabla 8
Presupuesto estimado del proyecto

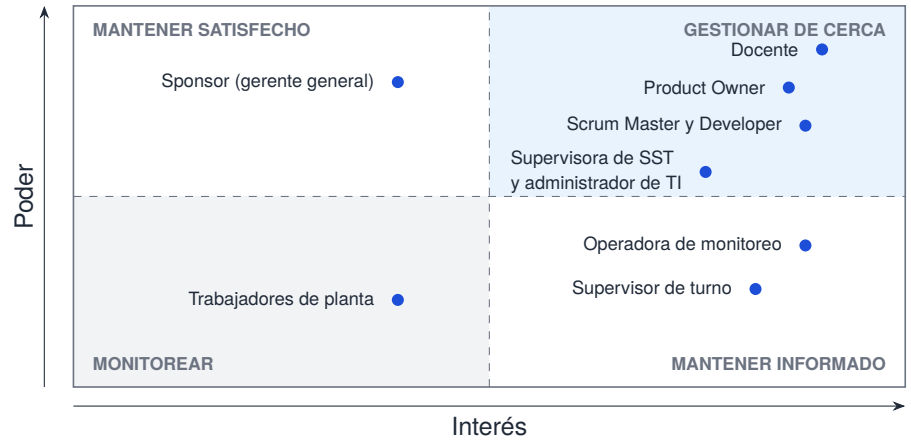
Concepto	Base de cálculo	Monto (S/)
Product Owner (Albert Chumacero)	100 h × S/ 40	4 000.00
Scrum Master y Developer (Anthony Lopez)	200 h × S/ 38	7 600.00
Developer (Luis Salazar)	200 h × S/ 35	7 000.00
Cómputo GPU en la nube	2 meses × S/ 40	80.00
Almacenamiento de videos, fotogramas y modelos	1 lote	150.00
Impresión y anillado de entregables	1 lote	50.00
Conjunto de datos (CC BY 4.0) y software abierto	Sin costo	0.00
Subtotal		18 880.00
Reserva de contingencia	10 % del subtotal	1 888.00
Total estimado		**20 768.00**

Nota. Base: 20 horas por semana por Developer y 10 por el Product Owner durante 10 semanas (500 horas). Importes referenciales al 12/10/2026, sin cotización formal.

4.3. FGAP020: Registro de interesados

El registro de interesados identifica a las personas que influyen en el proyecto o se ven afectadas por él, y define cómo involucrarlas. Se elaboró en este producto, en su versión 1.0, a partir de la lista de interesados del acta y de los roles del FGAP030. La Tabla 9 lo presenta y la Figura 2 ubica a cada interesado en una matriz de poder e interés.

Figura 2
Matriz de poder e interés de los interesados



Nota. Elaboración propia a partir de la Tabla 9.

La matriz orienta cómo se involucra a cada grupo. A quienes se *gestiona de cerca*, es decir, el Product Owner, el docente, los Developers y los usuarios de SST y de TI, se les convoca

Tabla 9
Registro de interesados (FGAP020)

Interesado	Rol en el proyecto	Expectativa principal	Poder	Interés
Ricardo Salcedo Paredes	Sponsor, gerente general	Indicadores claros para decidir inversión y capacitación	Alto	Medio
Albert Chumacero Chávarry	Product Owner	Un backlog que entregue valor en cada sprint	Alto	Alto
Dr. Alfredo Daza Vergaray	Docente del curso	Coherencia de los entregables con Scrum y la guía SBOK	Alto	Alto
Anthony Lopez Yrribarren	Scrum Master y Developer	Proceso sin impedimentos; integración y pruebas estables	Medio	Alto
Luis Salazar Diaz	Developer	Pipeline de visión reproducible y evaluado	Medio	Alto
Mariana Torres Cárdenas	Supervisora de SST	Alertas útiles con evidencia breve	Medio	Alto
Jorge Ponce Aguilar	Administrador de TI	Ingesta automática y configuración sin código	Medio	Alto
Lucía Ramos Villena	Operadora de monitoreo	Ver solo lo importante y confirmar en un clic	Bajo	Alto
César Vásquez Lozano	Supervisor de turno	Saber qué pasó, dónde y cuándo, sin alertas repetidas	Bajo	Alto
Trabajadores de planta	Personas observadas	Privacidad: sin rostro ni identificación	Bajo	Medio

Nota. Los interesados de la empresa son perfiles ficticios de un caso académico; no expresan un vínculo real con ninguna organización.

a la revisión de cada sprint, donde validan el incremento. Al sponsor se le *mantiene satisfecho* con un resumen breve al cierre de cada sprint, centrado en avance, riesgos y presupuesto. A la operadora de monitoreo y al supervisor de turno se les *mantiene informados*: prueban la interfaz en el Sprint 4, cuando se construye la parte que usarán. Los trabajadores de planta se *monitorean* a través de un compromiso explícito de privacidad: el sistema no reconoce rostros ni identifica a nadie.

4.4. FGAP030: Roles y prototipos

El FGAP030 describe a los usuarios del sistema mediante perfiles (*personas*). Cada rol se caracteriza por su frecuencia de uso, su experiencia en el tema, su dominio de la computadora y del software, y su meta al usar NewBit (Tabla 10). Los cinco roles son los actores de las seis épicas del backlog.

Los prototipos completan cada perfil con una breve historia personal. Mariana Torres, por ejemplo, reparte su día entre recorridos de planta y reportes; quiere enterarse de una con-

Tabla 10
Roles de usuario de NewBit (FGAP030)

Rol (persona)	Frecuencia de uso	Experiencia en el tema	Dominio del software	Meta principal
Administrador de la plataforma (Jorge Ponce, 35)	Diaria, al ingresar lotes	Alta	Alto	Cargar videos, configurar la selección de fotogramas y el umbral de confianza, y vigilar el rendimiento.
Supervisora de SST (Mariana Torres, 32)	Diaria y ante cada alerta	Alta	Medio	Revisar alertas con su clip de evidencia, confirmarlas o descartarlas y priorizar inspecciones.
Supervisor de turno (César Vásquez, 41)	Diaria, en su turno	Alta	Medio	Consultar las alertas de su área de mecanizado y registrar la acción tomada.
Operadora de monitoreo (Lucía Ramos, 29)	Permanente en su turno	Media	Alto	Atender alertas visuales y sonoras, verificar el clip y marcar falsas alarmas.
Gerente general y sponsor (Ricardo Salcedo, 48)	Semanal	Alta	Bajo	Consultar reportes por tipo, zona y semana para decidir recursos y capacitación.

Nota. Perfiles ficticios para fines académicos. La experiencia en el tema se refiere al dominio de cada persona: infraestructura en TI, prevención en SST y operaciones en los demás.

ducta insegura cuando todavía puede intervenir y saber en qué zonas se repite, sin revisar horas de video. Lucía Ramos vigila muchas cámaras a la vez y sabe que es fácil pasar algo por alto; quiere que NewBit le señale solo lo importante. Estas necesidades se traducen directamente en historias de usuario: la alerta con evidencia (HU10) y la vista del video con el recuadro de riesgo (HU09).

4.5. EGAP015: Justificación del proyecto

La justificación argumenta por qué conviene ejecutar el proyecto. Sigue los diez apartados del formato del docente (Daza Vergaray, 2026a) y se resume en la Tabla 11. En coherencia con el acta, el monto es el mismo, S/ 20 768, y no se prometen ahorros ni reducciones de accidentes que no estén demostrados.

Tabla 11
Síntesis de la justificación del proyecto (EGAP015)

Apartado	Síntesis
Necesidad	Las inspecciones de SST son intermitentes y las cámaras graban sin emitir alertas; los actos inseguros se identifican tarde.
Tecnológica	Arquitectura de dos etapas: YOLOv8 detecta a los operarios y permite descartar fotogramas sin actividad; ConvLSTM clasifica la secuencia. Pila abierta: Python, FastAPI y OpenCV.
Operativa	El flujo se reparte entre roles reales: TI administra la ingesta y los umbrales, SST analiza los incidentes y monitoreo atiende las alertas. El sistema apoya la decisión humana, no la reemplaza.
Económica	S/ 20 768, idéntico al acta: S/ 18 600 de dedicación valorizada, S/ 280 de gastos directos y S/ 1 888 de contingencia.
Social y de SST	Prevención de atrapamientos y accidentes en zonas de mecanizado; cultura preventiva; privacidad por diseño.
Académica	Aplicación de Scrum según la guía SBOK, ingeniería de requisitos, aprendizaje profundo, desarrollo web y pruebas.
Beneficios	Tangibles: plataforma web, pipeline de reducción de fotogramas, detector calibrado y registro de métricas. Intangibles: menos fatiga de revisión visual y mayor disciplina operativa.
Viabilidad	Técnica, operativa y económica, con las restricciones declaradas: procesamiento por lotes y dos conductas priorizadas.

Nota. Se omiten los apartados de datos generales y conclusión, que repiten información de la Tabla 4.

4.6. FGAP040: Épicas e historias de usuario

El backlog se organiza en seis épicas que siguen el recorrido del dato: del video cargado a la alerta (Tabla 12). Las épicas se descomponen en doce historias de usuario, cada una con dos criterios de aceptación verificables (Tabla 13).

Tabla 13
Historias de usuario y criterios de aceptación

HU	Historia de usuario	Criterios de aceptación
HU01	Como administrador de la plataforma, quiero cargar un video industrial (.mp4 o .avi), para iniciar el procesamiento visual.	Acepta .mp4 y .avi y rechaza otros formatos con un mensaje claro. Muestra nombre, duración, resolución y FPS.
HU02	Como administrador, quiero que el sistema fragmente el video en fotogramas normalizados, para prepararlos para la inferencia espacial.	Almacena fotogramas numerados en secuencia. Normaliza el tamaño al requerido por YOLOv8.

Tabla 13 (continuación)

HU	Historia de usuario	Criterios de aceptación
HU03	Como supervisora de SST, quiero que el sistema detecte a los operarios en cada fotograma con YOLOv8, para localizar la actividad humana.	Infiere cajas de la clase «persona» con su confianza. Muestra el fotograma con las cajas superpuestas.
HU04	Como administrador, quiero que se descarten los fotogramas sin trabajadores, para reducir la carga de cómputo.	Excluye los fotogramas sin detecciones. Registra fotogramas de entrada, conservados y porcentaje de reducción.
HU05	Como supervisora de SST, quiero agrupar los fotogramas activos en clips de tamaño fijo, para estructurar la entrada del modelo temporal.	Genera secuencias de N fotogramas consecutivos (configurable). Produce un tensor compatible con ConvLSTM.
HU06	Como supervisora de SST, quiero descartar los clips más cortos que una ventana mínima, para evitar alertas por movimientos fugaces.	Descarta los clips bajo el umbral de duración. Registra cuántos fragmentos se descartaron.
HU07	Como supervisora de SST, quiero procesar el clip con ConvLSTM, para extraer las dependencias temporales del movimiento.	Ejecuta la inferencia sobre la división oficial de prueba. Devuelve un vector de probabilidades por secuencia.
HU08	Como supervisora de SST, quiero que el modelo clasifique la conducta como segura o insegura y la tipifique, para registrar un diagnóstico claro.	Asigna etiqueta y tipo de conducta por clip. Calcula exactitud, precisión, sensibilidad y F1 por clase.
HU09	Como operadora de monitoreo, quiero ver el video con un recuadro de color según el riesgo, para validar la inferencia.	Recuadro verde (seguro) o rojo (inseguro) superpuesto. Permite reproducir, pausar y revisar los clips del lote.
HU10	Como operadora de monitoreo, quiero una alerta inmediata con hora y evidencia ante una conducta insegura, para intervenir a tiempo.	Notificación visual y sonora. Guarda fecha, marca de tiempo, clip y probabilidad.
HU11	Como administrador, quiero modificar el umbral de confianza de YOLOv8 desde la interfaz, para calibrar la sensibilidad según la iluminación.	Ajuste gráfico en el rango de 0 a 1 con validación de límites. Registra cada cambio en un log de auditoría.
HU12	Como gerente y administrador, quiero ver el log de tiempos y la aceleración obtenida, para evaluar la eficiencia técnica.	Muestra tiempos por fase (ingesta, YOLOv8, ConvLSTM). Compara el tiempo total con y sin reducción.

Tabla 12
Épicas del proyecto (FGAP040)

ID	Épica	Rol	Historias
EP01	Ingestión y preprocesamiento de video	Administrador	HU01, HU02
EP02	Detección espacial de operarios (YOLOv8)	Supervisora de SST	HU03
EP03	Segmentación y reducción de secuencias	Administrador, SST	HU04, HU05, HU06
EP04	Clasificación espacio-temporal (ConvLSTM)	Supervisora de SST	HU07, HU08
EP05	Monitoreo y visualización de alertas	Operadora de monitoreo	HU09, HU10
EP06	Administración, calibración y trazabilidad	Administrador, gerente	HU11, HU12

4.7. FGAP060: Backlog priorizado del producto

La priorización combinó tres criterios en este orden. Primero, la técnica MoSCoW fijó la criticidad de cada historia: ocho *Must*, tres *Should* y una *Could*. Segundo, cada integrante repartió 100 puntos entre las historias, lo que ordenó la importancia dentro de cada grupo. Tercero, se respetaron las dependencias técnicas del pipeline, porque ninguna etapa puede probarse sin la anterior. La estimación se hizo con el puño de cinco y se expresa en puntos de historia del 1 al 5. La Tabla 14 muestra el resultado.

Dos historias se adelantan a pesar de su baja votación. HU11 (*Could*) entra al Sprint 2 porque calibra el detector de HU03 y el filtro de HU04; sin ella no se pueden ajustar las pruebas de los sprints 2 y 3. HU06 (*Should*) también entra al Sprint 2, porque filtra los clips insuficientes antes de entrenar el modelo temporal en el Sprint 3. La carga queda equilibrada: 7, 8, 8 y 8 puntos por sprint.

Tabla 14
Backlog priorizado del producto (FGAP060)

HU	Historia (resumen)	MoSCoW	PO	SM	Dev	Total	Depende de	Sprint (pts)
HU01	Cargar video	Must	6	8	5	19	—	1 (1)
HU02	Extraer fotogramas	Must	5	8	7	20	HU01	1 (2)
HU03	Detectar operarios	Must	12	12	13	37	HU02	1 (4)
HU04	Descartar fotogramas vacíos	Must	8	10	10	28	HU03	2 (2)
HU05	Agrupar en clips	Must	6	9	10	25	HU04	2 (3)
HU06	Descartar clips cortos	Should	3	4	5	12	HU05	2 (2)
HU11	Calibrar umbral	Could	2	3	3	8	HU03	2 (1)
HU07	Procesar con ConvLSTM	Must	15	14	18	47	HU05	3 (5)
HU08	Clasificar y tipificar	Must	14	12	12	38	HU07	3 (3)
HU09	Ver video con recuadro	Must	13	9	8	30	HU08	4 (4)
HU10	Alerta de riesgo	Should	10	6	5	21	HU08	4 (2)
HU12	Ver log de tiempos	Should	6	5	4	15	HU04	4 (2)
	Total		100	100	100	300		31 pts

Nota. PO = Albert Chumacero; SM = Anthony Lopez; Dev = Luis Salazar. Las columnas PO, SM y Dev son los puntos que cada integrante asignó con el método de los 100 puntos. *Won't have* en esta versión: cámaras en vivo por RTSP, alertas físicas en la maquinaria y reconocimiento facial.

4.8. FGAP070: Criterios de terminado

Los criterios de terminado (CT-NB-001) se aplican a todas las historias. Una historia no pasa a la columna *Terminado* del tablero si no cumple cada uno de los criterios de la Tabla 15. A diferencia de los criterios de aceptación, que define el Product Owner para cada historia, estos criterios no se negocian por historia.

Tabla 15
Criterios de terminado del incremento (FGAP070)

Criterio	Condición para dar una historia por terminada
Prueba unitaria	Módulos nuevos o modificados con pruebas automatizadas ejecutadas; ninguna falla bloqueante o de regresión abierta.
Prueba integrada	Flujo verificado de extremo a extremo: interfaz web, API de carga, almacenamiento y motor de detección; manejo de videos corruptos, formatos no admitidos y parámetros fuera de rango.
Revisión de pares	Revisión del código entre los dos Developers: legibilidad, arquitectura modular, PEP 8 y ausencia de credenciales en el código.
Certificación	No aplica. Es un prototipo académico; no constituye certificación de SST ni sustituye al supervisor.
Documentación	Historias y criterios actualizados; manual de instalación y README; trazabilidad del conjunto de datos, versión de pesos, hiperparámetros y métricas.
Aprobación técnica	Los Developers confirman pruebas exitosas, ausencia de defectos graves y el incremento disponible en el entorno de demostración.
Aprobación administrativa	El Product Owner valida los criterios de aceptación en la revisión del sprint; su aceptación no sustituye los criterios técnicos.
Ética y privacidad	Licencia CC BY 4.0 respetada; sin reconocimiento facial ni biometría; alertas de carácter preventivo.

4.9. Arquitectura propuesta y plan de sprints

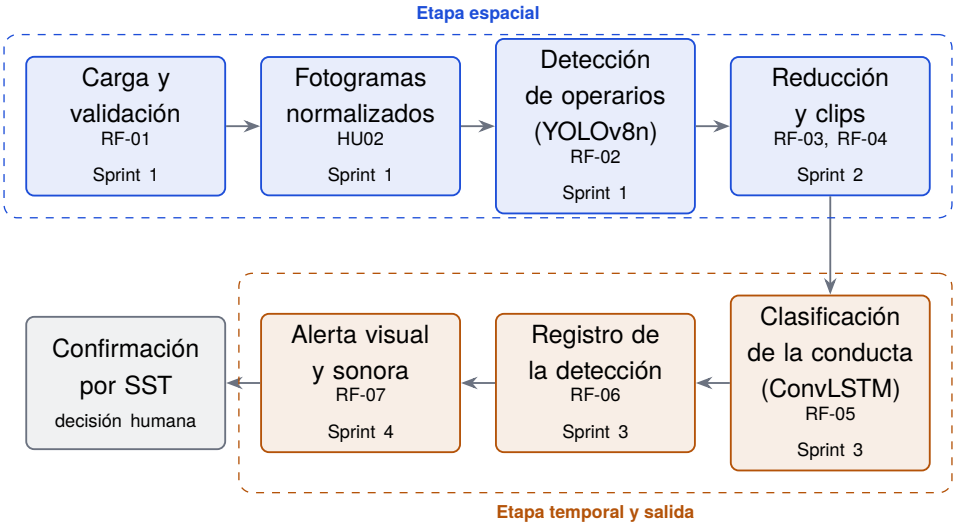
La Figura 3 muestra el pipeline propuesto. Adapta la arquitectura de Unsafe-Net (Önal y Dandıl, 2025) con un detector más reciente, YOLOv8n (Jocher et al., 2023), y la organiza en dos etapas. La *etapa espacial* trabaja fotograma por fotograma: valida el video, lo fragmenta, detecta a los operarios y conserva solo los fotogramas con actividad, que agrupa en clips. La *etapa temporal* clasifica cada clip con ConvLSTM y, si la conducta es insegura, registra la detección y emite la alerta. Al final, una persona de SST confirma o descarta la alerta. Separar ambas etapas permite evaluarlas por su cuenta, como exige el acta, y medir cuánto aporta la reducción de fotogramas al tiempo de procesamiento y a la exactitud.

La Figura 4 ubica los cuatro sprints en el calendario del semestre, con las épicas y la carga de cada uno. El Sprint 1 empieza el 19 de octubre de 2026, al cierre de la Unidad I.

El orden de los sprints sigue el recorrido del dato. Los sprints 1 y 2 construyen la etapa espacial, que no depende de ningún modelo entrenado por el equipo. El Sprint 3 concentra el mayor riesgo técnico: entrenar y evaluar el modelo ConvLSTM sobre la división oficial del conjunto de datos y comparar la clasificación directa con el pipeline completo. Las metas de desempeño se fijarán con la línea base que se obtenga en ese sprint; por eso este documento no adelanta cifras propias. El Sprint 4 lleva el resultado al usuario: visualización con recuadro de riesgo, alerta y log de tiempos.

Figura 3

Arquitectura propuesta del pipeline de NewBit



Nota. Elaboración propia. Los códigos RF remiten a la Tabla 5; el sprint indica cuándo se construye cada etapa según el backlog priorizado.

Figura 4

Plan de sprints de NewBit, octubre a diciembre de 2026



Nota. Fechas según el cronograma del acta (Tabla 7). En azul, la etapa espacial; en ámbar, la temporal y la interfaz.

Referencias

Bochkovskiy, A., Wang, C.-Y. y Liao, H.-Y. M. (2020). *YOLOv4: Optimal speed and accuracy of object detection* (arXiv:2004.10934). arXiv. https://doi.org/10.48550/arXiv.2004.10934

Clegg, D. y Barker, R. (1994). *Case method fast-track: A RAD approach*. Addison-Wesley.

Cohn, M. (2004). *User stories applied: For agile software development*. Addison-Wesley.

Congreso de la República del Perú. (2011, 20 de agosto). *Ley N.º 29783, Ley de Seguridad y Salud en el Trabajo*. Diario Oficial El Peruano.

Daza Vergaray, A. (2026a). *Justificación de negocio* [Diapositivas de clase]. Ingeniería de Software II, Universidad Nacional del Santa.

Daza Vergaray, A. (2026b). *Secuencia de trabajo del proyecto: Desde la definición del proyecto hasta la entrega final* [Material de clase]. Ingeniería de Software II, Universidad Nacional del Santa.

Gutiérrez Torres, M. M. (2022). *Visión computacional en la industria de la construcción: Identificación de equipos de seguridad en obras mediante el uso de deep learning* [Tesis de licenciatura, Pontificia Universidad Católica del Perú]. Repositorio de Tesis PUCP. http://hdl.handle.net/20.500.12404/23766

Heinrich, H. W. (1931). *Industrial accident prevention: A scientific approach*. McGraw-Hill.

Hochreiter, S. y Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, *9*(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Jocher, G., Chaurasia, A. y Qiu, J. (2023). *Ultralytics YOLOv8* (Versión 8.0.0) [Software]. https://github.com/ultralytics/ultralytics

LeCun, Y., Bengio, Y. y Hinton, G. (2015). Deep learning. *Nature*, *521*(7553), 436–444. https://doi.org/10.1038/nature14539

León León, R. A. y León Montero, J. A. (2024). Development of an artificial vision algorithm for the recognition of the correct use of EPP. En *Proceedings of the 4th LACCEI International Multiconference on Entrepreneurship, Innovation and Regional Development (LEIRD 2024)*. LACCEI. https://doi.org/10.18687/LEIRD2024.1.1.874

Machaca Arcana, L. A. (2019). *Reconocimiento de eventos anómalos en videos obtenidos de cámaras de vigilancia, usando redes convolucionales* [Tesis de licenciatura, Universidad Nacional de San Agustín de Arequipa]. Repositorio Institucional UNSA. http://repositorio.unsa.edu.pe/handle/UNSA/10849

Menzinsky, A., López, G. y Palacio, J. (2018). *Historias de usuario: Ingeniería de requisitos ágil* (Versión 2.0). Scrum Manager.

Önal, O. y Dandıl, E. (2021). Object detection for safe working environments using YOLOv4 deep learning model. *Avrupa Bilim ve Teknoloji Dergisi*, (26), 343–351. https://doi.org/10.31590/ejosat.951733

Önal, O. y Dandıl, E. (2024a). *Video dataset for safe and unsafe behaviours* (Versión 1) [Con-

junto de datos]. Mendeley Data. https://doi.org/10.17632/xjmtb22pff.1

Önal, O. y Dandıl, E. (2024b). Video dataset for the detection of safe and unsafe behaviours in workplaces. *Data in Brief*, *56*, Artículo 110791. https://doi.org/10.1016/j.dib.2024.110791

Önal, O. y Dandıl, E. (2025). Unsafe-Net: YOLO v4 and ConvLSTM based computer vision system for real-time detection of unsafe behaviours in workplace. *Multimedia Tools and Applications*, *84*, 34967–34993. https://doi.org/10.1007/s11042-024-19276-8

Paucara Guadalupe, C. E. R. y Rodríguez Enciso, S. P. (2024). *Sistema inteligente basado en deep learning para la detección del uso correcto de equipos de protección personal* [Tesis de licenciatura, Universidad César Vallejo]. Repositorio Digital Institucional UCV. https://hdl.handle.net/20.500.12692/149042

Redmon, J., Divvala, S., Girshick, R. y Farhadi, A. (2016). You only look once: Unified, real-time object detection. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 779–788). IEEE. https://doi.org/10.1109/CVPR.2016.91

Schwaber, K. y Sutherland, J. (2020). *La guía Scrum: La guía definitiva de Scrum: Las reglas del juego*. https://scrumguides.org

SCRUMstudy. (2022). *Guía de los fundamentos de Scrum (Guía SBOK)* (4.ª ed.). VMEdu.

Shi, X., Chen, Z., Wang, H., Yeung, D.-Y., Wong, W.-K. y Woo, W.-C. (2015). Convolutional LSTM network: A machine learning approach for precipitation nowcasting. En C. Cortes, N. Lawrence, D. Lee, M. Sugiyama y R. Garnett (Eds.), *Advances in Neural Information Processing Systems 28* (pp. 802–810). Curran Associates.